UNIVERZITET U NOVOM SADU

FAKULTET TEHNIČKIH NAUKA

DEPARTMAN ZA INDUSTRIJSKO INŽENJERSTVO I MENADŽMENT

DNEVNIK PRAKSE

IZVEŠTAJ O OBAVLJENOJ STUDENTSKOJ STRUČNOJ PRAKSI

NAZIV ORGANIZACIJE:
VegaIT

ORGANIZACIONA CELINA:
Data Solutions

TERMIN PRAKSE:
od **26.1.2026.**
do **20.2.2026.**

PREDSTAVNIK ORGANIZACIJE:
Aleksandar Pavlović

RUKOVODILAC STRUČNE PRAKSE:
Aleksandar Pavlović

STUDENT:
Konstantin Šec, I2 2/2026

Novi Sad, 2026

Studijski program: **MAS Inženjerski menadžment**
Usmerenje: **MAS Informacioni menadžment**
Ime i prezime studenta: **Konstantin Šec**
Broj indeksa: **I2 2/2025**

Vega Delivery Center Serbia d.o.o. Novi Sad
119 19/02/2026 vega IT

ZA: Fakultet tehničkih nauka

Univerzitet u Novom Sadu

Studijski program: MAS Inženjerski menadžment

Smer: Informacioni menadžment

POTVRDA O OBAVLJENOJ PRAKSI

Ovim se potvrđuje da je Konstantin Šec, broj indeksa: I2 2/2025, JMBG: 0607999820265,

student Fakulteta tehničkih nauka u Novom Sadu, obavio je stručnu praksu u kompaniji „Vega Delivery Center Serbia d.o.o. Novi Sad" u periodu od 26.01.2026. do 20.02.2026.

Student je tokom prakse implementirao Formula 1 Data Engineer aplikaciju.

Korišćeni alati, programski jezici i frameworks su: Docker, Airflow, Postgres, MinIO, Airflow, Kafka, Python, Data Modeling, Power BI.

Student Konstantin Šec je zadatke koji su mu postavljeni uspešno rešio.

Potvrda se izdaje na lični zahtev imenovanog, a radi podnošenja iste u studentsku službu

Fakulteta tehničkih nauka, kao dokaz o obavljenoj stručnoj praksi.

U Novom Sadu,

20.02.2026.

Vega Delivery Center Serbia d.o.o. Novi Sad

Vega Delivery Center Serbia d.o.o. Novi Sad

Novosadskog sajma 2, 9. Sprat
21000 Novi Sad, Serbia
+381 (0) 21 661 65 57
office@vegait.rs

Tekući račun:
265-2010310005214-33
Matični broj: 20444681
PIB: 105723766

1. UVOD – O ZNAČAJU STRUČNE PRAKSE

Studentska praksa je od 1970-ih godina uvedena u obrazovne sisteme većine naprednih ekonomija i vremenom postala neizostavni deo sistema obrazovanja i tržišta rada. Predstavlja najbolji način da mladi steknu radno iskustvo i time obezbede sebi prednost na tržištu rada u odnosu na kandidate bez prethodnog radnog iskustva. Važnost se ogleda u aktivnom uključivanju studenata u radno okruženje, čime celokupno društvo i privredni sistemi imaju mogućnost da zaposle kompetentne mlade stručnjake. Stručna studentska praksa predstavlja važan oblik nastavne aktivnosti, koji donosi povećanje efikasnosti, kako kod studenata, tako i u organizaciji u kojoj student obavlja praksu, što rezultira obostranim interesima. Spajanje novih ideja i inovacija iz teorijske potpore (fakultet) i praktična primena znanja i unapređenje radnog procesa (kompanija) rezultiraju povećanjem efikasnosti i efektivnosti na polju realnog tržišta. Studenti tokom stručne prakse dobijaju mogućnost povezivanja teoretskog znanja sa fakulteta kroz praktičnu primenu, zatim unapređenje poslovnih i ličnih profesionalnih znanja i veština, kao i podizanje kompetencije koja je neophodna za potrebe tržišta rada. Pored toga, ostvaruju veoma bitnu mrežu kontakata u okviru svoje profesije, ali i često ostvaruju svoje prvo zaposlenje nastavljajući da rade u firmi u kojoj su obavljali praksu, dakle stručna studentska praksa često predstavlja uspešan početak profesionalne karijere studenta. Praktična primena akademskog znanja predstavlja osnov za kreiranje uspešne karijere studenata, budućih zaposlenih u društvu znanja.

2. OSNOVNI PODACI O ORGANIZACIJI

Naziv organizacije: **VegaIT**

Adresa:

Novosadskog sajma 2

21000 Novi Sad, Srbija

Telefon: **+381 21 661 65 57**

E-mail: **contact@vegaitglobal.com**

Veb Sajt: **https://www.vegaitglobal.com/**

VegaIT je softverska kompanija osnovana u Novom Sadu, koja se bavi razvojem prilagođenih softverskih rešenja za klijente širom sveta. Kompanija je fokusirana na pružanje konsultantskih usluga, razvoj softverskh rešenja i digitalnog poslovnog okruženja.
Pored domaćeg tržišta, kompanija je tokom godina izrasla u međunarodnu kompaniju sa kancelarijama u više gradova kako Srbije tako i inostranstva. Portfolio kompanije se prožima kroz više različitih industrija, uključujući finansije, zdravstvo, mbanking, e-commerce i logistiku.

Osnonvne delatnosti kompanije su stručni poslovi koji se pre svega odnose na:

- Razvoj prilagođenih softverskih rešenja (web i mobilne aplikacije),
- Održavanje i unapređenje postojećih softverskih sistma,
- Konsalting u oblasti informacionih tehnologija i digitalne transformacije,
- Razvoj i implementaciju cloud rešenja i data platformi,
- Integraciju različitih informacionih sistema i servisa,
- Testiranje softvera i obezbeđenjne kvaliteta (QA),
- Upravljanje projektima i agilne metodologije razvoja kao što je Scrum,
- Edukaciju zaposlenih i razvoj tehničkih i profesionalnih veština unutar kompanije

3. ORGANIZACIONA STRUKTURA KOMPANIJE

U slučaju VegaIT kompanije ne postoji klasična organizaciona šema kao kada je reč o tradicionalnim inustrijskim sistemima. Umesti toga, VegaIT koristi kombinaciju **horizontalne (flat)** i **matrične** strukture stavarjući hibridnu organizaciju rada. Na ovaj način se izbegava klasična hijerarhija uvodeći fleksibilan model prilagođen projektno orijentisanoj IT industriji.

Flat (horizonatlna) komponenta podrazumeva minimalan broj hijerarhijskih nova. U slučaju flat-a ne postoji klasična piramidalna struktura menadžmenta, već kompletna komunikacija teče direktno i neformalnim kanalima. Zaposleni imaju visok stepen autonomije u radu a važne odluke se donose u okviru samih projektnih timova smanjujući potrebu za hijerarhijskim odobravanjem. Prednost ovakvog modela rada se pre svega ogleda u smanjenju birokratije, ubrzavanju razvoja i omogućavanja brže razmene informacija između različitih delova organizacije.

Matrična komponenta organizacione strukture uvodi dvostruku liniju odgovornosti, što je ključna karakteristika hibridnih organizacionih struktura. Na ovaj način je svaki zaposleni istovremeno deo funkcionalne linije i projektnog tima. Funkcionalne linije kao što su na primer razvoj softvera, QA i DevOps poseduju nadležnog *development lead-a* koji prati tehnički razvoj, napredak u karijeri developera i vrši evaluaciju performansi. Pored *development lead-a*, na scenu stupa i *team lead* ili *project manager* koji upravlja svakodnevnim zadacima, rokovima i isporukom za konkretnog klijenta.

Ovakva podela sugeriše da se tehnički i karijerni razvoj odvija kontinuirano unutar funkcionalne grupe. Pored toga, operativni rad se organizuje kroz dinamične projektne timove koji se formiraju i menjaju u zavisnosti od potreba projekta. Kombinacijom ova dva modela kompanija postiže fleksibilno formiranje timova u skladu sa zahtevima projekta, optimalno korišćenje resursa, paralelno unapređenje tehničkih kompetencija i smanjenje rigidnosti koja je tipična za tradicionalne industrijske sisteme.

4.OPIS REALIZOVANIH ZADATAKA U TORKU PRAKSE

4.1. Projektna specifikacija

vega IT

Data Engineering Internship

Data Engineering Internship

As a Data Engineering Intern, you will undertake a comprehednsive project aimed at building a robust data pipeline for Formula 1 data. The project encompasses multiple stages, including data modeling, ETL (Extract, Transform, Load) process creation using Apache Airflow and Python with Kafka, and the development of a PowerBI report.

Project Tasks:

Data Modeling:

- Utilize the provided Formula 1 dataset to design and implement a star schema.
- Identify relevant dimensions such as Race, Driver, Team, Circuit, and Time, along with the necessary fact tables.
- Define primary and foreign keys to establish relationships between dimension and fact tables.

ETL Process with Airflow and Kafka:

- Develop an ETL process using Apache Airflow to automate the extraction, transformation, and loading of data from the Formula 1 dataset into the star schema.
- Utilize Python to write custom operators within Airflow to handle data transformation tasks efficiently.
- Implement Kafka as a messaging system to ensure data streaming capabilities within the pipeline, enabling real-time data processing.

API Data Scraping:

- Identify a suitable API that provides additional Formula 1-related data
- Develop a Python script to scrape data from the chosen API.
- Integrate the scraped data into the existing data pipeline, ensuring compatibility with the established star schema.

PowerBI Report Creation:

Stražilovska 2
21000 **Novi Sad, Serbia**
www.omega.vegait.rs

- Utilize PowerBI to create an insightful and interactive report/dashboard based on the enriched Formula 1 dataset.
- Design visualizations to showcase key metrics such as race results, driver performance, team standings, and circuit statistics.
- Ensure the report provides actionable insights for stakeholders, including race strategists, team managers, and Formula 1 enthusiasts.

Deliverables:

- Documented star schema design including entity-relationship diagrams (ERDs) and schema definition.
- Python scripts for ETL processes implemented in Apache Airflow.
- Kafka configuration files and Python scripts for data streaming within the pipeline.
- Python script for API data scraping and integration.
- PowerBI report/dashboard showcasing key Formula 1 metrics and insights.

Evaluation Criteria:

- Completeness and correctness of the star schema design.
- Efficiency and reliability of the ETL process implemented with Airflow and Kafka.
- Effectiveness of API data scraping and integration into the pipeline.
- Quality and clarity of the PowerBI report/dashboard.
- Documentation quality, including code comments and explanatory notes.

Note:

This internship assignment is designed to provide practical experience in various aspects of data engineering, including data modeling, ETL processes, API integration, and data visualization. You are encouraged to seek guidance and assistance from mentors and peers throughout the project duration. Good luck, and have fun exploring the exciting world of Formula 1 data!

Stražilovska 2
21000 **Novi Sad, Serbia**
www.omega.vegait.rs

4.2.Uvod

Praksa je obavljena u oblasti data inženjeringa, sa ciljem projektovanja i implementacije sistema za prikupljanje, obradu i analizu podataka rezultata trke Formule 1. Tokom prakse izgrađen je kompletan data warehouse zasnovan na šemi sazvežđa[1] koja oslikava organizaciju podataka koji dolaze iz dva različita izvorna sistema. Osim samog skladišta podataka izgrađena je i kompletna arhitektura sa podsistemima potrebnim za efikasno funkcionisanje samog skladišta podataka. Za realizaciju ovog sveobuhvatnog sistema skladišta korišćen je niz različitih tehnologija. Od data modeling-a za projektovanje konceptualne šeme, preko konkretnih tehnologija za transformaciju i orkestraciju kao što su Python Pandas, Apache Kafka i Apache Airflow, alata za skladištenje podataka u staging zonama kao što je AWS MinIO S3, sistema za skladištenje relacione baze podataka u PostgreSQL-u, sve do Power-BI alata koji je služio kao sloj poslovne inteligencije za izvršavanje upita, vizualizaciju podataka i data analizu. Implementirana arhitektura obuhvata batch i streaming komponente, čime je pokrivena obrada kako istorijskih tako i tekućih podataka u produkciji.

4.3. Nedelja 1: Data Modeling – Projektovanje Data Warehouse arhitekture

Prva nedelja prakse bila je posvećena razumevanju domenskog problema i projektovanju data modela koji će kasnije predstavljati temelj celokupnog sistema. Najveći izazov u toku 1. nedelje bio je razumevanje izvornih sistema, kao i podataka i njhovih odnosa u okviru ovih sistema. Prvi sistem je na neki način predstavljao data lake u okviru kojeg su istorijski podaci bili sačuvani u CSV formatu. Analizom ovog sistema došlo se do zaključka da je reč o denormalizovanoj strukturi u okviru koje se u jednoj torki nalaze informacije o različitim realnim entitetima. Podaci iz drugog sistema nalazili su se na API endpoint-u čuvani u relanom vremenu i posedovali su daleko bolju organizaciju odnosa između samih entiteta. Početna ideja bila je projektovanje zvezdaste šeme koja bi centralizovala podatke iz ova dva sistema. Međutim, zbog kompleksnosti veza unutar samih podataka u domenu Formule 1 uvidelo se da bi šema sazvežđa, iako daleko kompleksnija, predstavljala prirodnije rešenje u slučaju pomenutog domena.

Na osnovu izvršene analize, bilo je potrebno identifikovati tabele dimenzija koje će predstavljati opisni kontekst entiteta, kao i činjenične tabele koje će reprezentovati merljive podatke. Identifikovano je pet dimenzionih i pet činjeničnih tabela.

Dimenzije:

- Vozač *(dim.driver),*
- Konstruktor *(dim.constructor),*
- Staza *(dim.circuit),*
- Trka *(dim.race),*
- Vreme *(dim.time)*

Činjenice:

- Rezultati trke *(fact.race_results),*
- Krugovi *(fact.laps),*
- Pit stopovi *(fact.pitstops),*
- Napredak vozača *(fact.driver_standings),*
- Napredak tima *(fact.constructor_standings)*

[1] Šema sazvežđa *(Constellation schema)* predstavlja proširenje i kompleksniju formu poznate zvezdaste šeme *(Star schema).*

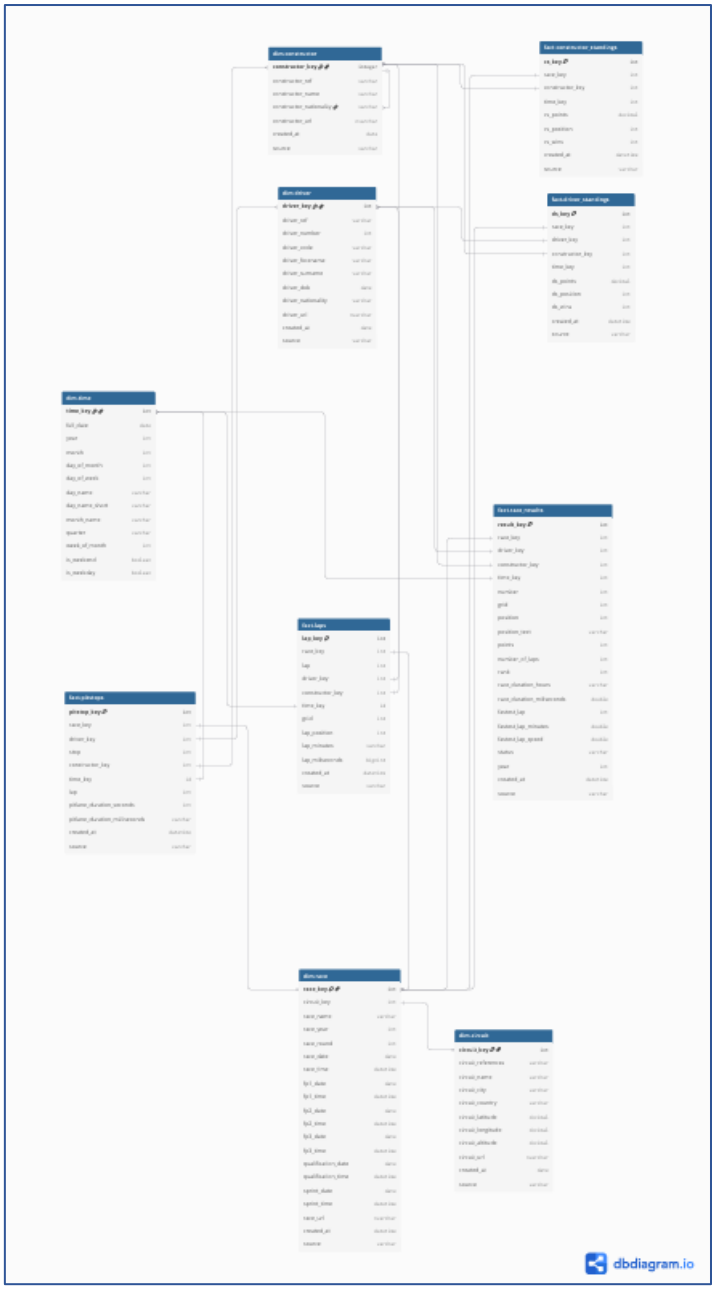

Slika 1 - Šema sazvežđa

Na slici 1 je prikazana šema sazvežđa koja objedinjuje opisane tabele dimenzija i činjenica.

Važno je još i napomenuti da je prilikom projektovanja konceptualne šeme korišćen *roll-up* pristup, koji je uspeo da obezbedi visok nivo granularnosti. U slučaju ovog projekta i s obzirom na kompleksnost veza unutar podataka odlučeno je da se granularnost u tabelama činjenica definiše na nivou pojedinačne trke. Na ovaj način svaki merljiv događaj ostaje direktno povezan sa svim relevantnim entitetima. Osim toga, ovakav pristup predstavlja čvrstu polaznu osnovu za buduća OLAP proširenja.

Već na početku prve nedelje bilo je potrebno definisati i politiku primarnih ključeva i njihove konsolidacije u okviru centralnog rešenja. Pomenuti CSV dataset koristi numeričke indikatore torke u opsegu od 1 do 857, s druge strane podaci na API endpoint-u iste entitete identifikuje kroz string vrednosti poput *"hamilton"* ili *"verstapen"*. Kako bi se izvršila pravilna integracija ova dva sistema bez kolizije ključeva i gubitka integriteta, koncepti prirodnog i surogat ključ su morali jasno da se razdvoje i definišu.

Vrednosti prirodnog ključa dolaze direktno iz izvornih sistema bez narušavanja vrednosti i jednistvenosti što ga čini idealnom tačkom spajanja ova dva sistema. Osim toga, u slučaju ovog projekta ali i kod kompleksijih data rešenja, prirodni ključ može da posluži i kao odličan identifikator samog izvornog sistema posmatrane torke u okviru centralnog skladišta podataka. Može se zaključiti da je uloga prirodnog ključa dvojaka, sa jedne strane predstavlja spojnicu dva različita izvorna sistema, dok s druge strane pravi jasnu razliku u pogledu identifikacije izvornog sistema.

Dalje je bilo potrebno implementirati i logiku surogat ključa koji će predstavljati interni i sistemski generisan integer na nivou centralnog skladišta podataka integrišući dva izvorna sistema u jedinstvenu celinu. Ovime je uloga glavnog identifikatora torke preseljena sa nivoa prirodnog ključa na nivo surogat ključa i time savladan problem da se vrednosti identifikatora istog posmatranog entiteta negde pojavljuju kao „hamilton“ a negde kao *'1'*.

Važno je još napomenuti i da u ovako isprojektovanom sistemu ključeva paralelno posmtranje vrednosti surogat i prirdnog ključa olakšava istorijska praćenja zaposlenima na analitčkom BI sloju.

4.4. Nedelja 2 – Arhitektura ETL procesa & Batch pipeline

Druga nedelja bila je posvećena implementaciji ETL procesa koji istorijske podatke iz CSV data lake-a transformiše u projektovano skladište podataka. U razgovoru sa mentorom odlučeno je da se koristi medaljonska (*medallion*) arhitektura kao arhitekturalni okvir. Ovakav pristup omogućava da se podaci organizuje u tri konceptualna sloja: *bronze, silver i gold*, pri čemu svaki sloj predstavlja viši stepen obrade, filtracije i kvaliteta podataka u odnosu na prethodni.

4.4.1.1. Bronze (raw) sloj

Bronze ili raw sloj predstavlja sirove i netransformisane podatke u izvornom obliku i u ovom slučaju sačuvane u data lake CSV fajlu. Podaci u okviru bronze sloja bili su preuzeti iz jedne ili više transakcionih OLTP baza podataka i predstavljaju akumulaciju transakcija iz perioda od 2013. do 2023. godine. Upravo zbog te akumulacije, problematika ovog sloja se pre svega ogleda u nestruktuiranom načinu čuvanja i reprezentovanja podataka u okviru CSV fajla. Iz konačnog skupa bilo je potrebno identifikovati veze između podataka i skladištiti ih u obliku podogodnom za izvršavanje BI operacija i data analize.

4.4.1.2. Silver sloj & prvi ETL

Opisani CSV fajl se učitava (**Extraction**) koristeći Python Pandas biblioteku, izvršava se čišćenje, standardizacija i transformacija (**Transformation**) po zadatim kriterijumima. Tako transformisani podaci se dalje čuvaju (**Load**) u *.parquet* formatu u staging zonama u MinIO S3 bucketu kreirajući silver sloj. MinIO je odabran kao besplatna alternativa poznatog AWS S3 koja omogućava lokalno pokretanje iste infrastrukture kakva se koristi i u produkcijskim cloud okruženjima.

U prvom ETL procesu, koji predstavlja tranziciju bronze i silver sloja, odvija se najveći broj transformacija neophodnih za reprezentovanje pročišćenih podataka u silver sloju. Neke od metoda i tehnika koje su korišćene u procesima transformacije u okviru ovog ETL procesa su:

- Metoda *drop_duplicates*
  Kako bi se približila ova metoda možemo da je zamislimo kao izvršavanje SELECT distinct * FROM drivers naredbe u SQL serveru. Dakle, ova metoda izuzima vozače se dupliciranim vrednostima po svim obeležjima, odnsono uzima samo vozače sa jedinstvenim vrednostima po svim obeležjima torke.
  Primer metode:
  ```
  drivers = df[[
        'driverId', 'driverRef', 'number_drivers', 'code',
        'forename', 'surname', 'dob', 'nationality', 'url'
    ]].drop_duplicates(subset=['driverId']).sort_values(["driverId"], ascending=True).copy()
  ```

- Metoda preimenovanja kolona u standardizovanu konvenciju definisanu u data katalogu:
  Primer metode:
  ```
  drivers = drivers.rename(columns={
        'driverId'      : 'driver_id',
        'driverRef'     : 'driver_ref',
        'number_drivers': 'driver_number',
        'code'          : 'driver_code',
        'forename'      : 'driver_forename',
        'surname'       : 'driver_surname',
        'dob'           : 'driver_dob',
        'nationality'   : 'driver_nationality',
        'url'           : 'driver_url'
    })
  ```

- Metoda konverzije datuma
  Primer metode:
  ```
  drivers['driver_dob'] = pd.to_datetime(drivers['driver_dob'], errors='coerce').dt.date
  ```

- Definisanje audit kolona za praćenje istorijskih vrednosti:
  Primer metode:
  ```
  drivers['created_at'] = pd.Timestamp.now()
  drivers['source'] = 'f1_data.csv'
  ```

- Generisanje surogat ključeva:
  Svakom redu se dodeljuje inerna integer vrednost od 1 naviše, inicijalizacija vrednosti se izvršava pomoću funkcije *range()*
  Primer metode:
  ```
  drivers = drivers.reset_index(drop=True)
  drivers.insert(0, 'driver_key', range(1, len(drivers) + 1))
  ```

Ovde se jasno može uočiti razlika između surogat i prirodnog *(business)* ključa. Surogat ključ kao što je *driver_key* je interni sekvencer bez poslovnog značenja. Surogat ključevi se najčešće koriste za SQL JOIN operacije unutar skladišta i garantuju bolju performantnost prilikom izvršavanja operacija spajanja u odnosnu na kompleksne prirodne ključeve koji mogu biti različitih tipova podataka.

4.4.1.3. Gold sloj & drugi ETL

Gold sloj predstavlja finalni sloj u okviru kojeg su podaci u potpunosti transformisani i filtrirani. Identifikovani i transformisani podaci u okviru dimenzija i činjenica se u ovom sloju reprezentuju kao korisničke tabele u PostreSQL.

Kada je reč o ETL procesu u okviru tranzicije silver i gold sloja on je daleko jednostavniji u poređenju sa prethodnim ETL-om, iz razloga što je većina kritičnih operacija već definisana i obrađena u prvom ETL procesu. U slučaju drugog ETL procesa podaci se učitavaju iz *.parquet* fajlova u MinIO S3 staging zonama, transformišu se i kao tabele čuvaju u PostgreSQL relacionoj bazi podataka.

Što se tiče samih transformacija u okviru ovog ETL-a najznačajnija je operacija obrade NULL vrednosti koja nije bila obrađena u prethodnom sloju. Zbog jasnije reprezentacije podataka na analitičkom BI sloju, odlučeno je da se NULL vrednosti u okviru string tipova definišu kao *'unknown', 'not held', 'no driver'* i drugim rečima u zavisnosti od posmatranog konteksta. Iz ograničenja koja proizilaza iz samih tipova podataka ovo nije bilo moguće sprovesti nad date i integer tipovima, te su NULL vrednosti u ovim slučajevima ostavljene u svom izvornom obliku.

Primer metode:

1. Definisanje metode:
```
def format_value_or_unknown(val):
    if pd.isna(val) or str(val) in ['None', 'NaT', 'nan', '', '<NA>', '\\N']:
        return 'unknown'
    return str(val)
```

2. Izvršavanje metode nad konkretnim kolonama:
```
df['driver_code']          =    df['driver_code'].apply(format_value_or_unknown)
df['driver_nationality']   =    df['driver_nationality'].apply(format_value_or_unknown)
df['driver_url']           =    df['driver_url'].apply(format_value_or_unknown)
```

4.4.2. Orkestracija pipeline-a

Kako bi se dobila jedinstvena kohezivna celina od opisanih ETL procesa kreiran je idempotentan batch pipeline, strogo poštujući redosled izvršavanja operacija. U kontekstu ovog projekta idempotencija predstavlja ključno arhitekturalno svojstvo i realizovanaa je pomoću naredbe DROP SCHEMA CASCADE koja se izvršava prilikom svakog pokretanja pipeline-a. Ovaj pristup omogućava brisanje i kreiranje nove šeme što je od ključne važnosti prilikom testiranja i razvoja u lokalnom okruženju, ali sa sobom nosi i određena ograničenja koja će detaljnije biti komentarisana u okviru zaključnog poglavlja.

Implementacijom ovog pipeline-a, kompletni istorijski podaci od 2013 do 2023. godine iz prvog data lake izvornog sistema uspešno su učitani u skladište podataka a celokupan proces orkestracije opisanog pipeline-a podržan je Apache Airflow-om.

Implementacijom prvog pipeline-a druga nedelja se privela kraju i zaključno sa tim ostalo je nerešeno pitanje tekućih podataka koji su se nalazili na API endpoint-u.

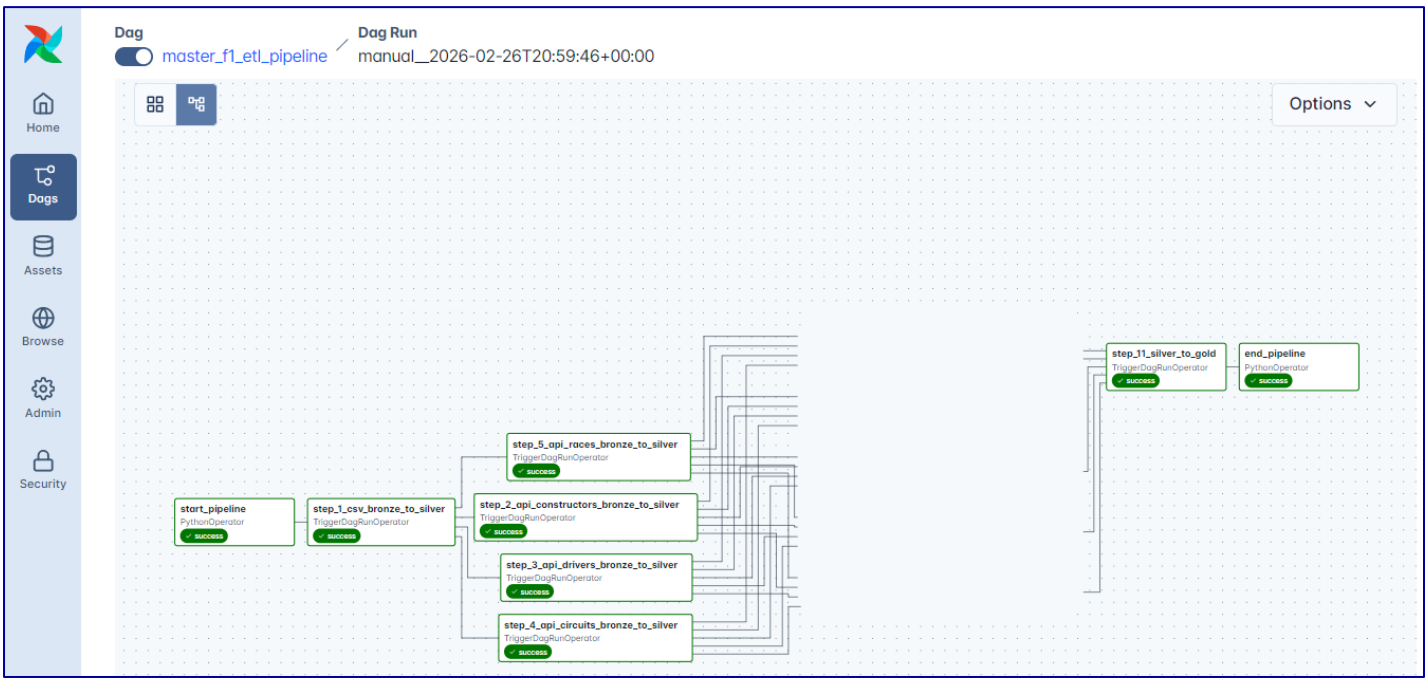

Slika 2 - Batch pipeline

Na slici 2 prikazan je opisani batch pipeline.

4.5. Nedelja 3 – API data scraping, Apache Kafka & inkrementalni real-time pipeline

Nakon što je batch pipeline uspešno izvršio obradu istorijskih podataka, treća nedelja je bila posvećena projektovanju rešenja za sledeći pipeline. Problem je bio kvalitativne prirode i glavno pitanje je bilo kako postojeći sistem učiniti sposobnim da automatski obrađuje nove podatke koji pristižu nedeljno sa API endpoint-a nakon završene F1 trke.

Pri izgradnji ovog pipeline-a tehnologije obrade bile su proširene scrapper klasama pisanim u objektno orijentisanoj paradigmi u Pythonu sa kojima se do tog momenta još nismo susretali. Definisana je bazna klasa BaseScraper koja predstavlja enkapsulaciju zajedničke logike. Koristeći ovu polaznu klasu bile su izgrađene specijalizovane klase za svaki entitet kao što su:

- DriverScraper,
- ConstructorScraper,
- RaceScraper,
- LapScraper,
- PitStopScraper i ostale.

Svaka klasa komunicira sa API endpoint-om, parsira JSON odgovor i vraća standardizovan Pandas DataFrame koji se transformiše i upisuje u silver a zatim i gold sloj. Posebnu pažnju zahtevala je konsolidacija novo pristiglih API podataka sa postojećim sistemom te je pojedina rešenja bilo potrebno proširiti i uskladiti sa novim zahtevima.

Centralna tehnologija treće nedelje bila je Apache Kafka koja je služila kao kanal za prenos novih zapisa od MinIO S3 silver do PostgreSQL gold sloja. Kafka arhitektura je podrazumevala dve glavne komponente, ondnosno Producer i Consumer. Ovakva arhitektura je dalje bila podržana Airflow orkestracijom što je sugerisalo izgradnju novog nezavisnog inkrementalnog pipeline-a za podatke koji su dolazili u realnom vremenu.

Producer komponenta preuzima podatke za tekuću sezonu sa API-ja, vrši identifikaciju i proveru prisutnosti novih vrednosti u silver sloju, dalje generiše vrednosti za surogat ključeve kako bi se osigurao kontinuitet bez preklapanja sa batch delom pipeline-a i naizad šalje ove vrednosti u silver sloj odakle ih Consumer komponenta preuzima.

Consumer dalje čita poruke odnosno nove vrednosti preuzete od Consumer-a, proverava njihovu prisutnost u gold sloju i ukoliko ne postoje upisuje ih u PostgreSQL odnosno bazu podataka.

Ključna razlika u odnosu na batch pipeline se ogleda u neidempotentnosti, odnosno šema se ne briše i ne kreira ponovo.

Na kraju treće nedelje sistem je bio sposoban da nedeljno automatski preuzima nove podatke nakon svake trke, upisuje ih u silver i gold slojeve bez manuelnih intervencija i uz visok stepen otpornosti na greške.

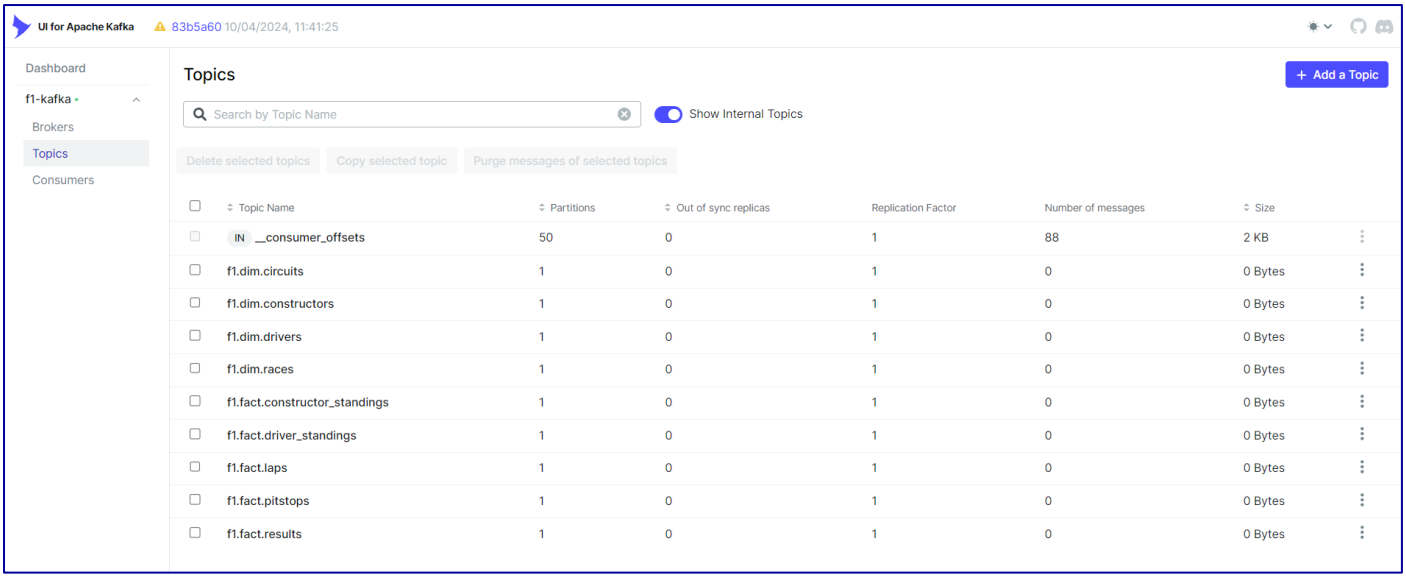

Slika 3 – Kafka

Na slici 3 prikazana je razmena poruka na Kafki.

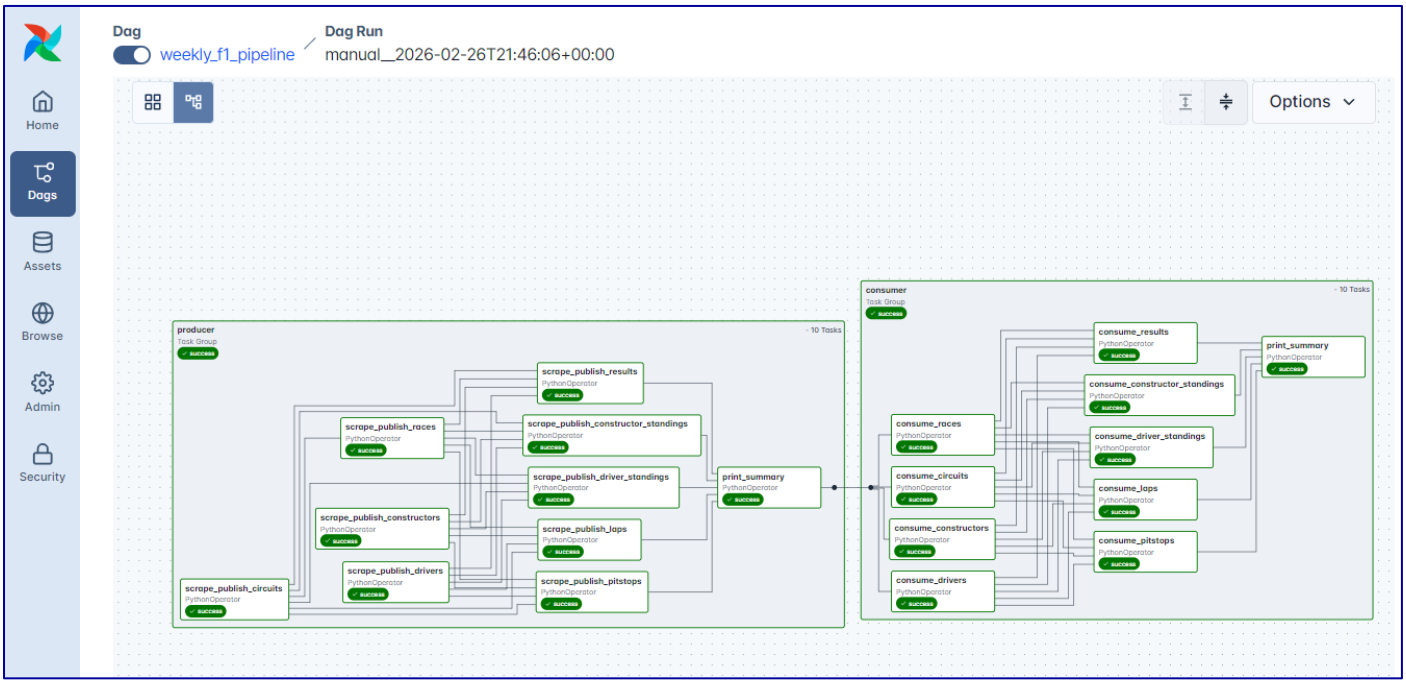

Slika 4 – Orkestracija inkrementalnog producer i consumer pipeline-a u Airflow-u

Na slici 4 prikazana je integracija producer i consumer komponente u jedinstveni inkrementalni pipeline u okviru Airflow-a.

4.6. Nedelja 4 – Analitika

4.6.1. SQL relaciona baza podataka

Dok su prve tri nedelje prakse bile fokusirane na pronalaženje inženjerskih rešenja, završna nedelja je bila posvećena prezentaciji tih rešenja kroz analitičke okvire u BI sloju. Poslednje nedelje je bilo neophodno izvršiti kreiranje SQL objekata i vizuelizaciju podataka u okviru logičkih celina koji će dalje biti upotrebljavani u analizi u Power BI alatu i PostgreSQL DBMS-u.

Posebna pažnja bila je posvećena kreiranju SQL pogleda koji predstavljaju osnovu analitičkog sloja i koji enkapsuliraju JOIN logiku između činjeničnih i dimenzionih tabela, prezentujući denormalizovane i čitljive skupove podataka.

4.6.2. Primeri pogleda

4.6.2.1. Pogled driver_standings

Query Query History

```
1 SELECT *
2 FROM vw_driver_standings
```

Data Output Messages Notifications

Showing rows: 1 to 1000

	ds_key bigint	ds_id bigint	race_key bigint	race_name text	driver_key bigint	driver_name text	constructor_key bigint	constructor_ref text	full_date date	ds_position bigint	ds_wins bigint
1	50	64978	1	Australian Grand Prix	1	Lewis Hamilton	1	mclaren	2012-03-...	3	0
2	59	64987	1	Australian Grand Prix	2	Nico Rosberg	11	mercedes	2012-03-...	12	0
3	52	64980	1	Australian Grand Prix	3	Fernando Alonso	5	ferrari	2012-03-...	5	0
4	65	64993	1	Australian Grand Prix	4	Heikki Kovalainen	14	caterham	2012-03-...	18	0
5	54	64982	1	Australian Grand Prix	5	Kimi Räikkönen	15	lotus_f1	2012-03-...	7	0
6	61	64989	1	Australian Grand Prix	7	Timo Glock	13	marussia	2012-03-...	14	0
7	64	64992	1	Australian Grand Prix	8	Felipe Massa	5	ferrari	2012-03-...	17	0
8	51	64979	1	Australian Grand Prix	10	Mark Webber	6	red_bull	2012-03-...	4	0
9	48	64976	1	Australian Grand Prix	11	Jenson Button	1	mclaren	2012-03-...	1	1
10	49	64977	1	Australian Grand Prix	12	Sebastian Vettel	6	red_bull	2012-03-...	2	0
11	53	64981	1	Australian Grand Prix	17	Kamui Kobayashi	8	sauber	2012-03-...	6	0
12	66	64994	1	Australian Grand Prix	19	Vitaly Petrov	14	caterham	2012-03-...	19	0
13	63	64991	1	Australian Grand Prix	20	Bruno Senna	2	williams	2012-03-...	16	0
14	60	64988	1	Australian Grand Prix	21	Pastor Maldonado	2	williams	2012-03-...	13	0
15	57	64985	1	Australian Grand Prix	22	Paul di Resta	7	force_india	2012-03-...	10	0
16	55	64983	1	Australian Grand Prix	23	Sergio Pérez	8	sauber	2012-03-...	8	0
17	56	64984	1	Australian Grand Prix	25	Daniel Ricciardo	4	toro_rosso	2012-03-...	9	0
18	58	64986	1	Australian Grand Prix	26	Jean-Éric Vergne	4	toro_rosso	2012-03-...	11	0
19	62	64990	1	Australian Grand Prix	27	Charles Pic	13	marussia	2012-03-...	15	0
20	3	64930	2	Malaysian Grand Prix	1	Lewis Hamilton	1	mclaren	2012-03-...	2	0
21	12	64939	2	Malaysian Grand Prix	2	Nico Rosberg	11	mercedes	2012-03-...	15	0
22	5	64932	2	Malaysian Grand Prix	3	Fernando Alonso	5	ferrari	2012-03-...	1	1
23	18	64945	2	Malaysian Grand Prix	4	Heikki Kovalainen	14	caterham	2012-03-...	21	0
24	7	64934	2	Malaysian Grand Prix	5	Kimi Räikkönen	15	lotus_f1	2012-03-...	7	0

Slika 5 - Pogled vw_driver_standings

Na slici 5 je prikazan pogled *vw_driver_standings* koji spaja fact tabelu plasmana vozača sa svim dimenzijama kako bi se na jednom mestu prikazali denormalizovani i kontekstualno obogaćeni podaci o poziciji i broju pobeda svakog vozača.

4.6.2.2. Pogled races_circuits

Query Query History

```
SELECT *
FROM vw_races_circuits
```

Data Output Messages Notifications

Showing rows: 1 to 304 Page No: 1 of 1

	race_key bigint	race_id bigint	race_name text	circuit_key bigint	circuit_references text	race_year bigint	race_round bigint	race_date date	race_time time without time zone	fp1_date character varying	fp1_time character varying	fp2_date character varying	fp2_time character va
1	1	860	Australian Grand Prix	1	albert_park	2012	1	2012-03-18	06:00:00	not held	not held	not held	not held
2	2	861	Malaysian Grand Prix	2	sepang	2012	2	2012-03-25	08:00:00	not held	not held	not held	not held
3	3	862	Chinese Grand Prix	15	shanghai	2012	3	2012-04-15	07:00:00	not held	not held	not held	not held
4	4	863	Bahrain Grand Prix	3	bahrain	2012	4	2012-04-22	12:00:00	not held	not held	not held	not held
5	5	864	Spanish Grand Prix	4	catalunya	2012	5	2012-05-13	12:00:00	not held	not held	not held	not held
6	6	865	Monaco Grand Prix	6	monaco	2012	6	2012-05-27	12:00:00	not held	not held	not held	not held
7	7	866	Canadian Grand Prix	7	villeneuve	2012	7	2012-06-10	18:00:00	not held	not held	not held	not held
8	8	867	European Grand Prix	11	valencia	2012	8	2012-06-24	12:00:00	not held	not held	not held	not held
9	9	868	British Grand Prix	8	silverstone	2012	9	2012-07-08	12:00:00	not held	not held	not held	not held
10	10	869	German Grand Prix	9	hockenheimring	2012	10	2012-07-22	12:00:00	not held	not held	not held	not held
11	11	870	Hungarian Grand Prix	10	hungaroring	2012	11	2012-07-29	12:00:00	not held	not held	not held	not held
12	12	871	Belgian Grand Prix	12	spa	2012	12	2012-09-02	12:00:00	not held	not held	not held	not held
13	13	872	Italian Grand Prix	13	monza	2012	13	2012-09-09	12:00:00	not held	not held	not held	not held
14	14	873	Singapore Grand Prix	14	marina_bay	2012	14	2012-09-23	12:00:00	not held	not held	not held	not held
15	15	874	Japanese Grand Prix	19	suzuka	2012	15	2012-10-07	06:00:00	not held	not held	not held	not held
16	16	875	Korean Grand Prix	23	yeongam	2012	16	2012-10-14	06:00:00	not held	not held	not held	not held
17	17	876	Indian Grand Prix	25	buddh	2012	17	2012-10-28	09:30:00	not held	not held	not held	not held
18	18	877	Abu Dhabi Grand Prix	20	yas_marina	2012	18	2012-11-04	13:00:00	not held	not held	not held	not held
19	19	878	United States Grand Prix	26	americas	2012	19	2012-11-18	19:00:00	not held	not held	not held	not held
20	20	879	Brazilian Grand Prix	16	interlagos	2012	20	2012-11-25	16:00:00	not held	not held	not held	not held
21	21	880	Australian Grand Prix	1	albert_park	2013	1	2013-03-17	06:00:00	not held	not held	not held	not held
22	22	881	Malaysian Grand Prix	2	sepang	2013	2	2013-03-24	08:00:00	not held	not held	not held	not held
23	23	882	Chinese Grand Prix	15	shanghai	2013	3	2013-04-14	07:00:00	not held	not held	not held	not held

Total rows: 304 Query complete 00:00:00.707 CRLF Ln 2, Col 23

Slika 6 - Pogled vw_races_circuits

Na slici 6 je prikazan pogled koji spaja dimenziju trke sa dimenzijom staze kako bi se na jednom mestu objedinile sve informacije o ova dva usko povezana entiteta. Takođe, prilikom projektovanja implementacione šeme došlo se do zaključka da tabela *races* predstavlja normalizaciju u odnosu na tabelu circuit što ove dve tabele čini odličnim kandidatom za njihovo spajanja u okviru pogleda.

4.6.2.3. Pogled races_circuits

Query Query History

```
SELECT *
FROM vw_results
```

Data Output Messages Notifications

Showing rows: 1 to 236 Page No: 1 of 1

	result_key bigint	result_id bigint	race_key bigint	race_name text	circuit_key bigint	circuit_references text	driver_key bigint	driver_number bigint	driver_name text	constructor_key bigint	constructor_ref text	year bigint	full_date date	grid bigint	position double precision	points double precision	rank double
1	3	21234	1	Australian Grand Prix	1	albert_park	1	4	Lewis Hamilt...	1	mclaren	2012	2012-03-...	1	3	15	
2	22	21258	2	Malaysian Grand Prix	2	sepang	1	4	Lewis Hamilt...	1	mclaren	2012	2012-03-...	1	3	15	
3	45	21282	3	Chinese Grand Prix	15	shanghai	1	4	Lewis Hamilt...	1	mclaren	2012	2012-04-...	7	3	15	
4	74	21311	4	Bahrain Grand Prix	3	bahrain	1	4	Lewis Hamilt...	1	mclaren	2012	2012-04-...	2	8	4	
5	98	21335	5	Spanish Grand Prix	4	catalunya	1	4	Lewis Hamilt...	1	mclaren	2012	2012-05-...	24	8	4	
6	118	21356	6	Monaco Grand Prix	6	monaco	1	4	Lewis Hamilt...	1	mclaren	2012	2012-05-...	3	5	10	
7	135	21376	7	Canadian Grand Prix	7	villeneuve	1	4	Lewis Hamilt...	1	mclaren	2012	2012-06-...	2	1	25	
8	175	21418	8	European Grand Prix	11	valencia	1	4	Lewis Hamilt...	1	mclaren	2012	2012-06-...	2	19	0	
9	187	21431	9	British Grand Prix	8	silverstone	1	4	Lewis Hamilt...	1	mclaren	2012	2012-07-...	8	8	4	
10	226	21471	10	German Grand Prix	9	hockenheimring	1	4	Lewis Hamilt...	1	mclaren	2012	2012-07-...	7	[null]	0	
11	227	21472	11	Hungarian Grand Prix	10	hungaroring	1	4	Lewis Hamilt...	1	mclaren	2012	2012-07-...	1	1	25	
12	271	21520	13	Italian Grand Prix	13	monza	1	4	Lewis Hamilt...	1	mclaren	2012	2012-09-...	1	1	25	
13	317	21567	14	Singapore Grand Prix	14	marina_bay	1	4	Lewis Hamilt...	1	mclaren	2012	2012-09-...	1	[null]	0	
14	322	21572	15	Japanese Grand Prix	19	suzuka	1	4	Lewis Hamilt...	1	mclaren	2012	2012-10-...	9	5	10	
15	349	21601	16	Korean Grand Prix	23	yeongam	1	4	Lewis Hamilt...	1	mclaren	2012	2012-10-...	3	10	1	
16	364	21619	17	Indian Grand Prix	25	buddh	1	4	Lewis Hamilt...	1	mclaren	2012	2012-10-...	3	4	12	
17	406	21664	19	United States Grand Prix	26	americas	1	4	Lewis Hamilt...	1	mclaren	2012	2012-11-...	2	1	25	
18	447	21707	20	Brazilian Grand Prix	16	interlagos	1	4	Lewis Hamilt...	1	mclaren	2012	2012-11-...	1	[null]	0	
19	452	21716	21	Australian Grand Prix	1	albert_park	1	10	Lewis Hamilt...	11	mercedes	2013	2013-03-...	3	5	10	
20	471	21736	22	Malaysian Grand Prix	2	sepang	1	10	Lewis Hamilt...	11	mercedes	2013	2013-03-...	4	3	15	
21	492	21758	23	Chinese Grand Prix	15	shanghai	1	10	Lewis Hamilt...	11	mercedes	2013	2013-04-...	1	3	15	
22	514	21782	24	Bahrain Grand Prix	3	bahrain	1	10	Lewis Hamilt...	11	mercedes	2013	2013-04-...	9	5	10	
23	543	21811	25	Spanish Grand Prix	4	catalunya	1	10	Lewis Hamilt...	11	mercedes	2013	2013-05-...	2	12	0	

Slika 7 - Pogled 'vw_results'

Na slici 7 je prikazan pogled *vw_results* predstavljajući ujedno i najkompleksniji analitički pogled u sistemu. Fact tabela sa rezultatima trka se spaja sa svih pet dimenzija kao što su *driver, constructor, circuit, race* i *time*. Na ovaj način se izlaže celokupan kontekst svakog rezultata zajedno sa metrikama poput pozicije na startu, osvojenih bodova, broja krugova kao i vreme najbržeg kruga.

4.6.3. Indeksne strukture

Kada je reč o indeksnim strukturama važno je naglasiti da primarni ključevi automatski generišu B-stabla pri kreiranju tabele u okviru PostgreSQL-a. Ovo dalje implicira da JOIN operacije između činjeničnih i dimenzionih tabela po tim ključevima već imaju optimalnu indeksnu podršku bez potrebe za dodatnom konfiguracijom. Eksplicitno dodavanje indeksa po navedenom kriterijumu bi u ovom slučaju unelo redundantnost bez benefita. Kako su se sva spajanja u okviru pomenutih pogleda izvršavala isključivo na osnovu vrednosti primarnih ključeva, a koji su sistemski već bili indeksirani, u ovoj fazi životnog ciklusa dodavanje indeksnih struktura po vrednostima nekih drugih obeležja ne bi bila od posebnog značaja.

4.6.4. Power BI vizuelizacija

Na osnovu kreiranih pogleda, podaci su vizualizovani u Power BI alatu. Ideja je bila da pogledi služe kao osnova za izveštaje i dashboard-ove koji ilustruju ključne analitičke dimenzije poput performansi vozača i timova kroz sezone, analizu vremena krugova po stazama, pit stop vremena kao i distribuciju bodova.

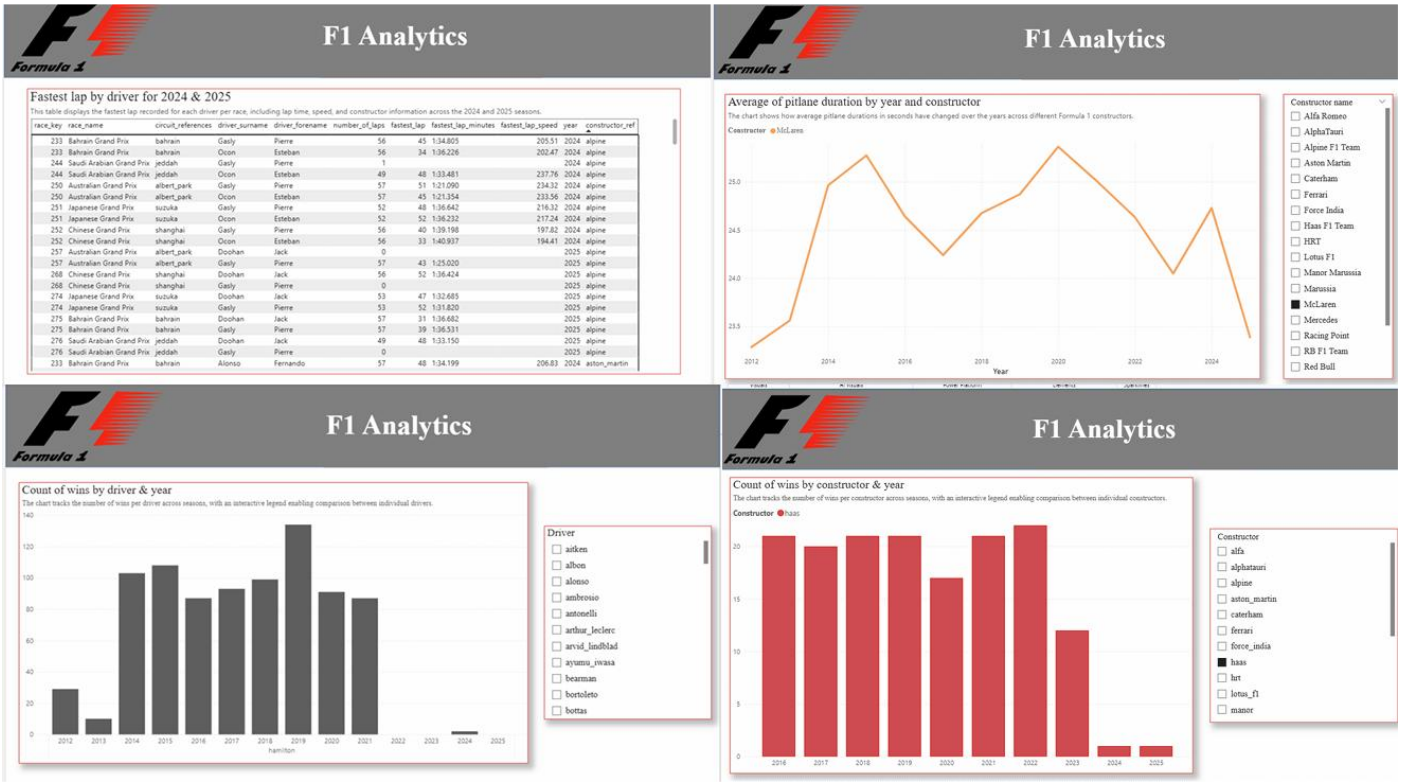

Slika 8 - PowerBI dashboard primeri

Na slici 8 prikazana je detaljnija vizuelizacija pomenutih pogleda.

5. ZAKLJUČAK

Tokom četiri nedelje prakse realizovao sam kompletan data warehouse sistem koji obuhvata ključne koncepte izgradnje modernog skladišta podataka. Ovo je podrazumevalo promišljeno projektovanje počevši od konceptualnog modela, kroz implementaciju ETL procesa zasnovanih na medaljonskoj arhitekturi, do batch i inkrementalnog streaming pipeline-a i analitičkog BI sloja. Sistem bi u celini demonstrira kako teorijsko tako i praktično razumevanje koje sam stekao tokom studija i prakse. Odluke koje sam donosio u koordinaciji sa mentorom tokom razvoja poput uvođenja šeme sazvežđa umesto zvezdaste šeme i uvođenje dva sistema primarnih ključeva pokazuje da je arhitektura bila promišljena a ne samo vođena projektnom specifikacijom.

Ipak, postoji nekoliko aspekata koji pružaju prostor za potencijalna unapređenja u budućnosti. Možda i najvažniji arhitekturalni nedostatak se odnosi na sam koncept idempotentnosti u batch pipeline-u. Iako je pristup zasnovan na 'DROP SCHEMA CASCADE', vrlo praktičan u razvojnom lokalnom okruženju, on ipak ne predstavlja najidealniji scenario u produkcijskom okruženju. Pored toga što kompletno rušenje i ponovno kreiranje implementacione šeme baze podataka nije poželjno sa nivoa performantnosti, ovakav pristup ne pruža ni istorijsko praćenje izmena nad entitetima. Predlog je da se opisani mehanizam zameneni upsert logikom koja bi sprovodila ažuriranje nad postojećim zapisima sa jedne strane i upisivala nove zapise ukoliko za tim postoji potreba sa druge strane. Ukoliko bi došlo do promena vrednosti atributa ili veza unutar istih, one bi trebale da budu tretirane u okviru update logike upsert-a. Na primer, promene rasporeda staza na trci ili nova raspodela vozača po timovima u slučaju inkrementalnog pipeline-a u ovom sistemu ne tretiraju uopšte, što svakako predstavlja značajan nedostatak.

Pomenut nedostatak nameće prirodno rešenje implementacijom **SCD Type 2** *(Slowly Changing Dimensions Type 2)* mehanizma, što svakako i predstavlja standard u sistemima koji zahtevaju istorijsko praćenje promena nad dimenzijama. Predlog implementacije **SCD Type 2** mehanizma bi se ogledao u dodavanju novih *valid_from, valid_to i is_current* kolona u okviru tabela dimenzija. Na ovaj način zaposleni na analitičkom sloju uvek mogu da rekonstruišu stanje dimenzije u bilo kom trenutku u prošlosti, što je svakako od posebnog značaja u domenu Formule 1 gde vozači menjaju timove između i tokom sezona. S tim u vezi, smatram da projektovani sistem predstavlja solidnu i funkcionalnu osnovu koja demonstrira razumevanje ključnih principa data inženjeringa. Nedostaci koje sam istekao nisu posledica loših odluka već kompromisa koji su karakteristični za svaki kompleksniji sistem koji se razvija u ograničenom vremenskom okviru.